Power BI pour débutants : consommation électrique de campus

4 cartes KPI, 3 graphiques, 4 segments et 2 info-bulles, à partir des données BDG2 (2016-2017)

Contenu	Pour qui
1. Introduction 2. Diagnostic 3. Nettoyage 4. Modèle en étoile 5. Power Query, pas à pas 6. Mesures DAX 7. Cartes KPI 8. Graphiques 9. Segments 10. Info-bulles 11. Pièges et sources Annexe : corrections	Débutant en Power BI. Chaque étape correspond à ce qui a été fait sur le projet.

Les étapes, les noms de colonnes, les formules DAX et les chiffres de contrôle correspondent au projet réalisé. La section 5 indique aussi quelles tables ne doivent pas être chargées dans le modèle.

1. Introduction : c'est quoi ces données ?

Les données proviennent du **Building Data Genome Project 2** (BDG2), un jeu de données ouvert publié par Miller et al. dans la revue *Scientific Data* en 2020. Elles décrivent la consommation électrique horaire de bâtiments non résidentiels, sur deux ans (2016 et 2017). Le site Panther correspond à l'Université de Floride centrale, à Orlando, selon les coordonnées du fichier.

Fichier	Contenu	Taille
metadata.csv	Une ligne par bâtiment : usage, site, surface (sqm), et d'autres colonnes non utilisées	1 636 lignes, 32 colonnes
electricity_cleaned.csv	Une ligne par heure ; une colonne par bâtiment ; valeur = kWh consommés pendant l'heure	17 544 lignes, 1 579 colonnes

Unités. 1 MWh = 1 000 kWh ; 1 GWh = 1 000 000 kWh.

Terme Power BI	Ce que c'est, en clair
Table	Un tableau de données (par exemple, les mesures horaires).
Colonne	Une information de la table (par exemple, kWh ou primaryspaceusage).
Relation	Un lien entre deux tables sur une colonne commune (par exemple, la date).
Mesure	Un calcul en DAX, recalculé à chaque filtre. Elle ne prend pas de place dans les données.
Segment (slicer)	Une liste ou une liste déroulante qui filtre tout le tableau de bord.
Info-bulle	Une petite page qui s'affiche au survol d'un graphique.

2. Diagnostic des données

Contrôle	Résultat mesuré	Pourquoi c'est important
Période	1er janvier 2016 à 31 décembre 2017 ; 17 544 heures	2016 est bissextile (366 jours)
Cellules vides	8,9 % en moyenne ; 90 bâtiments à plus de 50 % de vides ; 6 entièrement vides	Une cellule vide n'est pas un zéro
Valeurs aberrantes	Compteur Dottie : 221 228 kWh en une heure ; 99e percentile de 1 656 kWh	Elles fabriquent un faux pic
Pics à retirer	Seuil fixe : 14 heures. Méthode du 99e percentile : 23 heures, 12 bâtiments	Voir section 3.2
Bâtiments sans série	58 bâtiments des métadonnées n'ont aucune mesure	Ils ne doivent pas être comptés comme actifs
Libellés	Usage manquant pour 21 bâtiments ; « Residence Hall » suivi d'une tabulation	Un libellé mal écrit crée une catégorie en double
Sites et usages	19 sites ; 16 usages (dont « Non renseigné »)	Définit la taille des tables Dim_Site et Dim_Usage

3. Nettoyage : données manquantes et anomalies

3.1 Données manquantes

Une cellule vide signifie que le compteur n'a pas transmis de valeur. **Ne la remplacez jamais par 0** : un zéro affirme que le bâtiment n'a rien consommé, ce qui fausse les moyennes. Dans ce projet, les cellules vides sont **supprimées** : les sommes et les moyennes les ignorent de toute façon, et la table devient plus légère. Les 6 bâtiments entièrement vides et les 58 bâtiments sans série sont gérés par la colonne **Actif** (section 5, étape 7).

3.2 Anomalies (pics aberrants) : la méthode retenue

Méthode retenue : un seuil fixe. Toute heure où un bâtiment consomme 20 000 kWh ou plus est retirée. C'est la méthode appliquée dans Power Query (filtre « Inférieur à 20000 »). Ses résultats sont les chiffres de contrôle de ce guide.

Indicateur	Avant nettoyage	Après nettoyage (seuil fixe)
Heures retirées	-	14 heures
Pic horaire du portefeuille	482,3 MWh (6 sept. 2017, 15 h), dû au seul compteur Dottie	312,5 MWh (11 mai 2016, 15 h)
Consommation totale	3 653,7 GWh	3 652,8 GWh

Méthode avancée (facultative) : le 99e percentile. Une heure est suspecte si elle dépasse 20 fois le 99e percentile du compteur, quand ce percentile est supérieur à 50 kWh. Cette méthode retire 23 heures au lieu de 14. Par rapport au seuil fixe, elle retire 15 heures supplémentaires, sur des compteurs à faible consommation habituelle, et elle ne retire pas 6 heures que le seuil fixe retire (valeurs supérieures à 20 000 kWh sur des compteurs à forte consommation habituelle). Le pic horaire reste 312,5 MWh avec les deux méthodes. Elle demande un calcul de percentile, difficile à réaliser dans l'interface de Power Query : elle est réservée à une version plus avancée du projet.

Choix de méthode. Les deux méthodes ne sont pas équivalentes : le seuil fixe est plus simple et suffisant pour ce tableau de bord. Mentionnez-le dans votre rapport.

3.3 Autres nettoyages

Problème	Action dans Power Query
Libellé d'usage avec tabulation (« Residence Hall »)	Transformer > Format > Supprimer les espaces (Trim)
Usage manquant (21 bâtiments)	Colonne conditionnelle : si primaryspaceusage est vide, alors « Non renseigné »
Colonne sqm	La renommer en Surface_m2
Colonnes inutiles	Ne garder que building_id, site_id, primaryspaceusage et sqm dans metadata.csv

4. Modèle de données en étoile

Une table de faits (les mesures) est au centre, entourée de tables de dimensions (date, site, usage, bâtiment). Le filtre part des dimensions vers les faits.

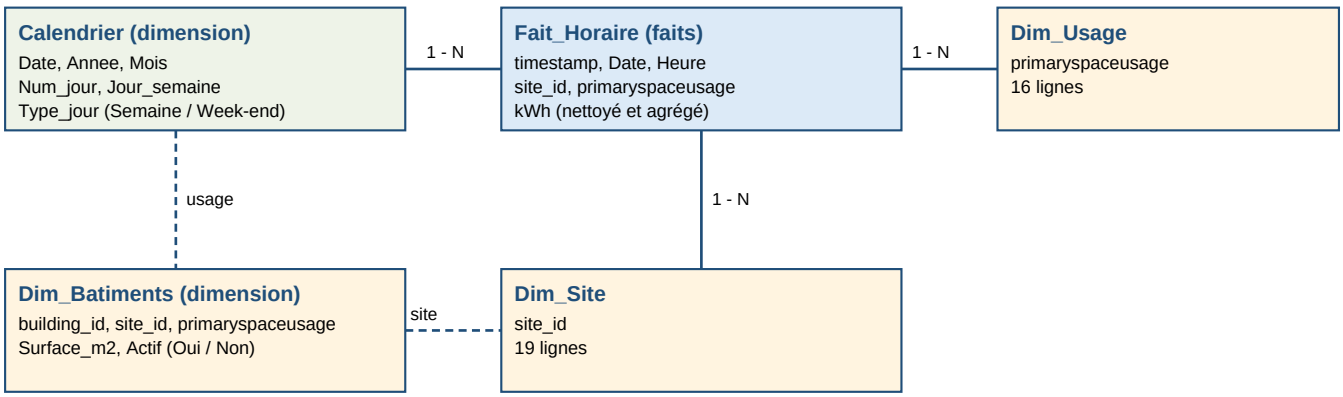


Figure 1. Schéma du modèle. Traits pleins : relations principales vers la table de faits. Pointillés : liens entre Dim_Batiments et les dimensions Site et Usage.

Relations à créer (toutes en un-à-plusieurs, filtre dans une seule direction) :

Du côté « un »	Vers le côté « plusieurs »
Calendrier[Date]	Fait_Horaire[Date]

Du côté « un »	Vers le côté « plusieurs »
Dim_Site[site_id]	Fait_Horaire[site_id]
Dim_Usage[primaryspaceusage]	Fait_Horaire[primaryspaceusage]
Dim_Site[site_id]	Dim_Batiments[site_id]
Dim_Usage[primaryspaceusage]	Dim_Batiments[primaryspaceusage]

Règle. Direction du filtre croisé : **Unique**. Jamais « À double sens », car elle crée des ambiguïtés et des calculs faux. Marquez Calendrier comme table de dates.

5. Power Query, pas à pas

Ces étapes reprennent exactement ce qui a été fait sur le projet. Vérifiez le nombre de lignes et le total après chaque étape importante.

Requête A : electricity_cleaned

1. Importer electricity_cleaned.csv. Power Query lit les 1 579 colonnes ; la première ligne contient les noms de bâtiments.

2. Sélectionner la colonne **timestamp** (type Date/Heure). Puis **Transformer > Dépivoter les autres colonnes**. Renommer **Attribut** en **building_id** et **Valeur** en **kWh**.

3. Cliquer sur l'icône ABC 123 de la colonne kWh, puis choisir **Nombre décimal**. Sans ce réglage, le filtre numérique n'est pas proposé.

4. Filtrer kWh : **Filtres numériques > Inférieur à > 20000**. Ce filtre retire les heures suspectes (méthode retenue) et les cases vides.

5. Vérifier qu'aucune valeur **(null)** ne reste dans kWh, puis décocher (null) si besoin. Compter les lignes : environ **25,2 millions** sont attendues.

6. Ajouter **timestamp** en colonne Date seulement (**Ajouter une colonne > Date > Date seulement**), nommée **Date**, et une colonne **Heure** (**Ajouter une colonne > Heure > Heure**).

7. Fusionner avec Dim_Batiments (requête de la section B) sur **building_id**, en jointure **Externe gauche**. Développer uniquement **site_id** et **primaryspaceusage**, **sans préfixe**. Si le préfixe reste, renommer les colonnes en site_id et primaryspaceusage.

8. Regrouper par : **Transformer > Regrouper par > Avancé**. Regrouper par **timestamp, Date, Heure, primaryspaceusage, site_id**. Nouvelle colonne **kWh**, opération **Somme**, colonne **kWh**. Ne pas garder building_id dans le regroupement.

9. Renommer la requête en **Fait_Horaire**. Vérifier que la table contient environ **2 millions de lignes au maximum**.

Requête B : Dim_Batiments (metadata.csv)

10. Importer metadata.csv. Ne garder que building_id, site_id, primaryspaceusage et sqm. Renommer sqm en **Surface_m2**. Renommer la requête en **Dim_Batiments**.

11. Supprimer les espaces de primaryspaceusage (Trim), puis remplacer les vides par « Non renseigné » avec une colonne conditionnelle.

12. Créer la colonne **Actif** : dans une requête intermédiaire **Actifs_Temp**, grouper electricity_cleaned par building_id avec le maximum de kWh (nom kWh_max). Fusionner Dim_Batiments avec Actifs_Temp, développer kWh_max, puis ajouter une colonne personnalisée : **if [kWh_max] = null then "Non" else "Oui"**. Supprimer kWh_max. Désactiver le chargement d'Actifs_Temp (clic droit > Activer le chargement).

Requête C : Dim_Site et Dim_Usage

13. Clic droit sur Dim_Batiments > **Référence**. Dans la copie, ne garder que **site_id**, puis **Supprimer les lignes > Supprimer les doublons**. Vérifier : **19 lignes**. Renommer en Dim_Site.

14. Même opération avec **primaryspaceusage** : **16 lignes**. Renommer en Dim_Usage. Si un doublon « Rat » ou une valeur en double apparaît, appliquer d'abord Supprimer les espaces.

Chargement

15. **Accueil > Fermer et appliquer**. Attendre la fin du chargement, puis vérifier qu'aucun triangle n'apparaît sur les requêtes.

Tables du modèle. Après chargement, le volet Données doit afficher Mesures, Calendrier, Dim_Batiments, Dim_Site, Dim_Usage et Fait_Horaire. La table Mesures sert à ranger toutes les mesures : elle est normale. Actifs_Temp est une table intermédiaire : elle ne doit pas être chargée dans le modèle.

Attention. Ne fermez pas Power Query en cours de regroupement : l'opération peut prendre plusieurs minutes. Si un triangle apparaît sur une requête, cliquez sur l'étape rouge pour lire le message d'erreur avant toute autre action.

6. Mesures DAX

Créez les mesures dans la table **Mesures** (clic droit sur Mesures > Nouvelle mesure). Les formules utilisent les colonnes de Fait_Horaire et de Dim_Batiments : cela fonctionne depuis n'importe quelle table du modèle.

6.1 Table Calendrier (à créer une fois, via Modélisation > Nouvelle table)

```
Calendrier =
ADDCOLUMNS (
    CALENDAR ( DATE ( 2016, 1, 1 ), DATE ( 2017, 12, 31 ) ),
    "Annee", YEAR ( [Date] ),
    "Mois", FORMAT ( [Date], "MMMM" ),
    "Num_jour", WEEKDAY ( [Date], 2 ),
    "Jour_semaine", FORMAT ( [Date], "dddd" ),
    "Type_jour", IF ( WEEKDAY ( [Date], 2 ) >= 6, "Week-end", "Semaine" )
)
```

6.2 Mesures (table Mesures)

```
Total kWh = SUM ( Fait_Horaire[kWh] )

Total GWh = DIVIDE ( [Total kWh], 1000000 )

Nb jours = DISTINCTCOUNT ( Fait_Horaire[Date] )

Moyenne journaliere MWh = DIVIDE ( DIVIDE ( [Total kWh], [Nb jours] ), 1000 )

Pic horaire MWh =
DIVIDE (
    MAXX (
        SUMMARIZE ( Fait_Horaire, Fait_Horaire[timestamp],
                    "Conso_h", SUM ( Fait_Horaire[kWh] ) ),
        [Conso_h]
    ),
    1000
)

Moyenne horaire MWh =
DIVIDE (
    DIVIDE ( SUM ( Fait_Horaire[kWh] ), DISTINCTCOUNT ( Fait_Horaire[timestamp] ) ),
    1000
)

Part du total =
DIVIDE ( [Total GWh], CALCULATE ( [Total GWh], ALL ( Dim_Usage ) ) )
```

6.3 Mesure dans Dim_Batiments

```
Nb batiments actifs =
CALCULATE ( COUNTROWS ( Dim_Batiments ), Dim_Batiments[Actif] = "Oui" )
```

Remarque : la colonne Actif contient du texte (« Oui » / « Non »). La condition doit donc être écrite entre guillemets, et non avec TRUE().

Valeurs de contrôle (méthode retenue, sans segment) : Total GWh = 3,65 (3 652,8) ; Moyenne journalière = environ 4 997 MWh ; Pic horaire = 312,5 MWh ; Nb batiments actifs = 1 572 ; Moyenne horaire = 177,1 MWh à 3 h et 237,0 MWh à 14 h. Si vous obtenez autre chose, revérifiez le filtre de la section 5, étape 4, avant les formules.

7. Cartes KPI (4 maximum)

Carte	Mesure	Valeur de contrôle	Affichage
Consommation totale	Total GWh	3,65 (3 652,8 GWh)	Format sans unité d'affichage, 2 décimales

Carte	Mesure	Valeur de contrôle	Affichage
Moyenne journalière	Moyenne journaliere MWh	environ 4 997 MWh	Afficher les vraies valeurs (Unités d'affichage : Aucun)
Pic horaire	Pic horaire MWh	312,5 MWh	Afficher les valeurs en entier
Bâtiments actifs	Nb batiments actifs	1 572 sur 1 636	Afficher le total dans le titre

Les cartes peuvent afficher « 3.7K » ou « 5.0K » par défaut. Dans Format visuel > Valeur, réglez **Unités d'affichage** sur **Aucun** et **Nombre de décimales** selon la carte.

8. Trois graphiques

Question	Visuel	Où mettre quoi
Comment évolue la consommation dans le temps ?	Graphique en courbes	Axe : Calendrier[Date] ; Valeurs : Moyenne journaliere MWh
Quel usage consomme le plus ?	Barres horizontales	Axe : Dim_Usage[primaryspaceusage] ; Valeurs : Total GWh ; trier par décroissant
Quelle est la forme d'une journée type ?	Graphique en courbes	Axe : Fait_Horaire[Heure] ; Valeurs : Moyenne horaire MWh

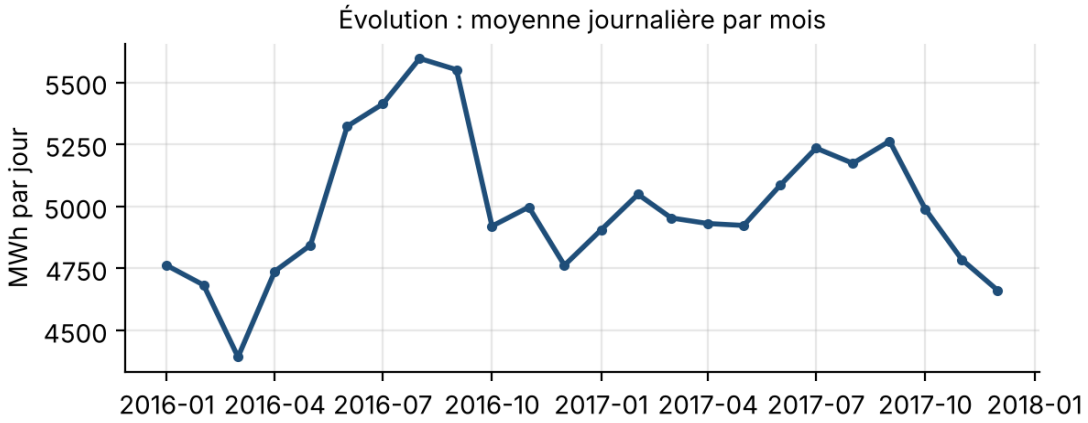


Figure 2. Moyenne journalière par mois. Minimum en mars 2016 (environ 4 393 MWh par jour), maximum en août 2016 (environ 5 596 MWh par jour).

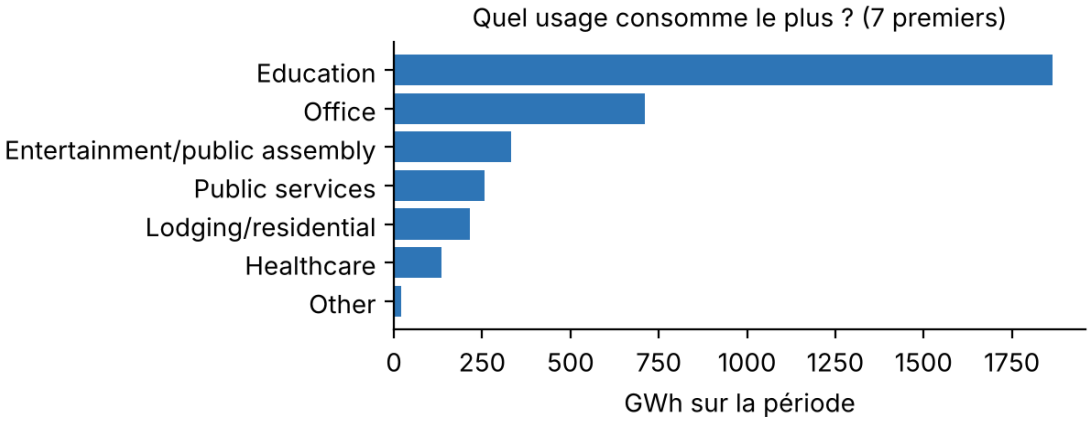


Figure 3. Education : 1 865,2 GWh, soit 51,3 % de la consommation. Office : 710,8 GWh. Les autres usages sont loin derrière.

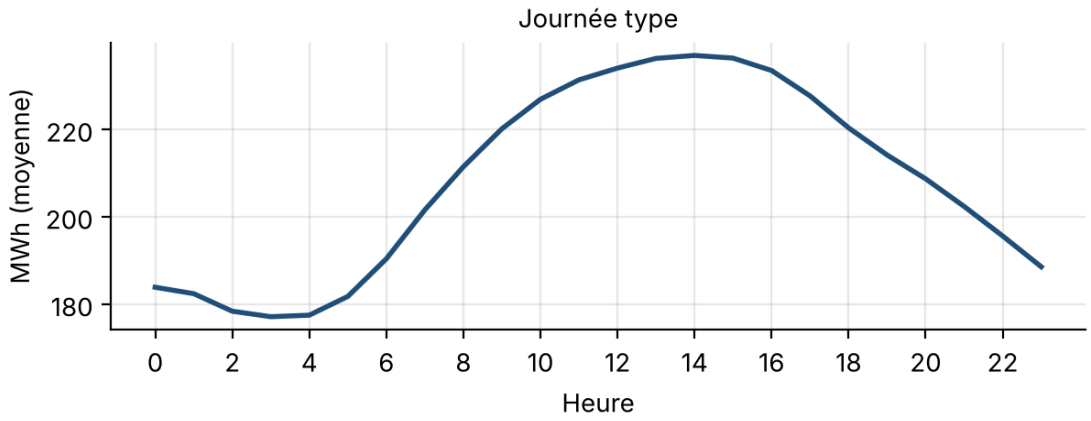


Figure 4. Consommation la plus basse vers 3 h (177,1 MWh en moyenne), la plus haute vers 14 h (237,0 MWh).

9. Quatre segments pour filtrer

Segment	Colonne	Style conseillé
Année	Calendrier[Annee]	Liste (2 valeurs)
Type de jour	Calendrier[Type_jour]	Liste (2 valeurs)
Usage	Dim_Usage[primaryspaceusage]	Liste déroulante, placée en bas de page
Site	Dim_Site[site_id]	Liste déroulante, placée en bas de page (19 valeurs)

Liste déroulante et direction. Power BI ouvre la liste vers le bas, et ne permet pas de choisir la direction. Pour qu'elle s'ouvre vers le haut, placez le segment au bas de la page, là où il n'y a plus de place en dessous.

10. Deux info-bulles

Une info-bulle est une page de type Info-bulle (320 × 240 px) qui s'affiche au survol d'un graphique.

10.1 Info-bulle temps (page Info_temps)

1. Créer une page nommée Info_temps, Type de page : **Info-bulle**, 320 × 240 px.
2. Ajouter un graphique en courbes : Axe = **Heure** (Fait_Horaire), Valeurs = **Moyenne horaire MWh**. Titre : « Profil horaire du jour (MWh) ».
3. Sur la page principale, cliquer sur le graphique **Moyenne journalière MWh par Date**, puis dans Format visuel > Info-bulle, activer **Afficher la page d'info-bulle** et choisir Info_temps.

Au survol d'une date, l'info-bulle affiche les 24 heures de cette journée. Le filtre de date est transmis automatiquement.

10.2 Info-bulle usage (page Info_usage)

1. Créer une page nommée Info_usage, Type de page : **Info-bulle**, 320 × 240 px.
2. Ajouter un graphique à barres : Axe = **site_id** (Dim_Site), Valeurs = **Total GWh**. Filtre visuel : Top N, 5 éléments. Titre : « Répartition par site (GWh) ».
3. Sur la page principale, cliquer sur le graphique **Total GWh par primaryspaceusage**, puis activer **Afficher la page d'info-bulle** et choisir Info_usage.

Au survol de la barre Education, l'info-bulle affiche les sites qui contribuent à cet usage.

11. Pièges fréquents

Symptôme	Cause probable et action
Le pic horaire affiche 482 MWh	Le filtre « Inférieur à 20000 » n'est pas appliqué. Revenir à la section 5, étape 4.
Une requête affiche un triangle	Cliquer sur l'étape rouge pour lire le message. Souvent une colonne renommée ou supprimée dans une requête liée.
Une carte ou un graphique affiche 0	Relation manquante, ou direction à double sens. Vérifier Gérer les relations.

Symptôme	Cause probable et action
Les barres par usage sont vides	Vérifier que Total GWh a le bon format, et que les étiquettes ne sont pas à 0.0K (Unités d'affichage : Aucun).
Les étiquettes sont illisibles	Choisir une couleur claire (#F2F2F2) dans Étiquettes de données et Valeur.
Une mesure donne une erreur	Vérifier les noms exacts : timestamp (et non Horodatage), Actif (texte « Oui »/« Non »).

12. Limites et sources

Limites. Le seuil d'anomalie est un choix de méthode. Les fuseaux horaires des horodatages ne sont pas documentés : les heures de pointe doivent être interprétées avec prudence. Les noms de sites et de bâtiments sont des pseudonymes du jeu de données.

Jeu de données. Miller, C., Kathirgamanathan, A., Picchetti, B., et al. (2020). The Building Data Genome Project 2, energy meter data from the ASHRAE Great Energy Predictor III competition. *Scientific Data*, 7, 368. DOI : 10.1038/s41597-020-00712-x.

Fonctions DAX. Documentation Microsoft : https://learn.microsoft.com/fr-fr/dax/ . Cette documentation n'a pas été consultée lors de la rédaction de cette version ; vérifiez la syntaxe si une fonction échoue.

Annexe : corrections apportées au guide

Partie	Première rédaction	Version actuelle
Anomalies (3.2)	Règle du 99e percentile présentée comme méthode principale	Seuil fixe 20 000 kWh retenu ; 99e percentile en méthode avancée
Comparaison des méthodes	Le seuil fixe était décrit comme « rate 6, retient 15 »	Corrigé : le seuil fixe signale 6 heures de plus, et ne signale pas 15 heures de la méthode du percentile
Total de contrôle	3 652,9 GWh	3 652,8 GWh
Power Query	7 étapes génériques	Étapes réelles : colonnes, filtre, Actif, Dim_Site, Dim_Usage, regroupement en mode Avancé
Nom de colonne	Horodatage	timestamp
Nb batiments actifs	Actif = TRUE()	Actif = "Oui" (colonne texte)
Emplacement des mesures	Table _Mesures	Toutes les mesures dans la table Mesures (formules inchangées)
Dim_Batiments	Colonne Année	Colonne Surface_m2 ; Année retirée
Info-bulles	Absentes	Section 10 ajoutée
Tables du modèle	Non précisé	Actifs_Temp non chargée ; table Mesures conservée pour ranger les mesures